

PMCSN: Right Sizing Spike Server

Modello di simulazione e analisi delle prestazioni

Luca Falasca

`luca.falasca@students.uniroma2.eu`

Università degli Studi di Roma Tor Vergata

Roadmap

1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale
 - Seed e stream
 - Gestione del parallelismo

3 Analisi Transitorio

- Variazione SI_{max}
- Variazione λ

4 Orizzonte temporale

5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

6 Conclusioni

Caso di Studio

- Problema del Right Sizing con spike server
- Bilanciamento spreco di risorse e performance
- Gestione picchi di carico improvvisi
- Problema di scelta della soglia SI_{max}



Obiettivi dello studio

1 Ottimizzazione soglia

- ▶ Trovare SI_{max} ottimale per $E[R] < 8s$ con carico $\lambda = 6.66$ req/s

2 Stress test

- ▶ Analizzare il tempo di risposta sotto carichi crescenti (1-12 req/s) variando la soglia SI_{max} tra 10 e 160

3 Upgrade spike server

- ▶ Ripetere l'analisi di stress test con un server spike con tasso di servizio raddoppiato

Roadmap

1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale
 - Seed e stream
 - Gestione del parallelismo

3 Analisi Transitorio

- Variazione SI_{max}
- Variazione λ


4 Orizzonte temporale

5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

6 Conclusioni

Modello concettuale



Logica operativa

- Se $SI < SI_{max}$ -> Web server
- Se $SI = SI_{max}$ -> Spike server

Sistema

- **Scheduling:** Processor sharing
- **Stato del sistema:**
 $S(t) = (SI(t), n_{spike}(t))$
 - ▶ $SI(t)$: Utenti nel Web server
 - ▶ $n_{spike}(t)$: Utenti nello Spike server

Parametri del modello

Carico di lavoro

Processo iperesponenziale
($cv = 4$)

- **Caso Base:** $\lambda = 6.66$ req/s
- **Stress Test:**
 $\lambda = \{1, 2, \dots, 12\}$ req/s

Tempi di servizio

Distribuzione iperesponenziale
($cv = 4$)

- **Web server:** $E[S] = 0.16s$
- **Spike server (Base):**
 $E[S] = 0.16s$
- **Spike server (Upgrade):**
 $E[S] = 0.08s$

Seed e stream

Per tutti gli esperimenti è stato utilizzato un solo seed (8) con differenti stream

- Indipendenza tra variabili casuali generate
- Indipendenza tra le repliche
- Riproducibilità degli esperimenti

è stata utilizzata la libreria rngs con i parametri:

- $MODULUS = 2147483647$
- $STREAMS = 256$
- Capacità singolo stream = $MODULUS/STREAMS = 8388608$

Gestione del parallelismo

Per velocizzare le simulazioni è stato implementato un sistema di parallelismo

- 3 stream per processo (3 variabili casuali)
- Ogni processo esegue un numero fisso di repliche
- L'estrazione per ogni replica parte da dove si è fermata la precedente
- 100 repliche per ogni simulazione

Roadmap

1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale
 - Seed e stream
 - Gestione del parallelismo

3 Analisi Transitorio

- Variazione SI_{max}
- Variazione λ

4 Orizzonte temporale

5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3


6 Conclusioni

Analisi Transitorio

L'analisi del transitorio è stata effettuata per determinare il tempo necessario affinché il sistema raggiunga lo stato stazionario.

- Intervallo 0-5000s
- Seed utilizzati 8, 9, 10, 11, 12, 13, 14
- Analisi per il caso base ($SI_{max} = 80$, $\lambda = 6.66$ req/s)
- Analisi al variare di SI_{max} e λ
- Intervallo di campionamento: 100s

Analisi Transitorio $SI_{max} = 80$, $\lambda = 6.66$ req/s



- 0-500s: Maggiore variabilità
- 500-1500s: Stabilizzazione
- Oltre 1500s: Fase transitoria conclusa

Variazione SI_{max}




Figure 1: Andamento del tempo di risposta medio per $SI_{max} = 40$ e $\lambda = 6.66$ con diversi seed




Figure 2: Andamento del tempo di risposta medio per $SI_{max} = 120$ e $\lambda = 6.66$ con diversi seed

Variazione λ




Figure 3: Andamento del tempo di risposta medio per $SI_{max} = 80$ e $\lambda = 3$ con diversi seed




Figure 4: Andamento del tempo di risposta medio per $SI_{max} = 80$ e $\lambda = 9$ con diversi seed

Roadmap

1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale
 - Seed e stream
 - Gestione del parallelismo

3 Analisi Transitorio

- Variazione SI_{max}
- Variazione λ

4 Orizzonte temporale


5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

6 Conclusioni

Orizzonte temporale

- Tempo di simulazione totale: 5000s
 - ▶ Tempo adeguato per raggiungere la fase stazionaria in tutti i casi
 - ▶ Tempo di simulazione per fattibilità computazionale
- Fase di warm-up: 500s
 - ▶ Esclusa la parte iniziale per evitare l'influenza del transitorio
 - ▶ Alternativa possibile: 1500s



Roadmap

1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale
 - Seed e stream
 - Gestione del parallelismo

3 Analisi Transitorio

- Variazione SI_{max}
- Variazione λ

4 Orizzonte temporale


5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

6 Conclusioni

Obiettivo 1

Scenario con carico $\lambda = 6.66$ req/s: analisi del tempo di risposta medio in funzione della soglia SI_{max} .



- Il tempo di risposta cresce all'aumentare di SI_{max}
- $SI_{max} = 90$ è a rischio
- $SI_{max} = 80$, massimizza l'uso del webserver mantenendo $E[R] < 8s$

Obiettivo 2

- Fino a $\lambda = 7$ req/s

- $E[R] \nearrow$

- $SI < SI_{max}$

- da $\lambda = 8$ req/s

- Spike server in azione


- $E[R] \searrow$

- da $\lambda = 11$ req/s

- Saturazione spike server


- $E[R] \nearrow$

Scenario con vari scenari di soglia: analisi del tempo di risposta medio in funzione di $\lambda = 1, 2, \dots, 12$ req/s.



Obiettivo 3

Spike server potenziato del doppio
($E[S] = 0.08s$): analisi del tempo di risposta
medio in funzione di $\lambda = 1, 2, \dots, 12$ req/s.



- Comportamento equivalente all'obiettivo 2
- Spike server non si satura più

Roadmap

1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale
 - Seed e stream
 - Gestione del parallelismo

3 Analisi Transitorio

- Variazione SI_{max}
- Variazione λ

4 Orizzonte temporale

5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

6 Conclusioni

Conclusioni

- Con carico di lavoro base ($\lambda = 6.66$ req/s), soglia ottimale $SI_{max} = 80$
- Per $\lambda > 11$ necessario potenziare lo spike server
- Spike server va dimensionato in base al carico di lavoro atteso

Grazie per l'attenzione!

Domande?

Il codice è disponibile al seguente repository:

<https://github.com/LucaFalasca/RightSizing-SpikeServer>