

# PMCSN: Right Sizing Spike Server

## Modello di simulazione e analisi delle prestazioni

Luca Falasca

`luca.falasca@students.uniroma2.eu`

Università degli Studi di Roma Tor Vergata

# Roadmap

## 1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

## 2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale

## 3 Analisi Transitorio

## 4 Orizzonte temporale

## 5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

# Caso di Studio

- Problema del Right Sizing con spike server
- Bilanciamento spreco di risorse e performance

# Obiettivi dello studio

## 1 Ottimizzazione soglia

- ▶ Trovare  $SI_{max}$  ottimale per  $E[R] < 8s$  con carico  $\lambda = 6.66$  req/s

## 2 Stress test

- ▶ Analizzare il tempo di risposta sotto carichi crescenti (1-12 req/s) variando la soglia  $SI_{max}$

## 3 Upgrade spike server

- ▶ Ripetere l'analisi di stress test con un server spike con tasso di servizio raddoppiato

# Roadmap

## 1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

## 2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale


## 3 Analisi Transitorio

## 4 Orizzonte temporale

## 5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

# Modello concettuale



## Logica operativa

- Se  $SI < SI_{max}$  -> Web server
- Se  $SI = SI_{max}$  -> Spike server

## Sistema

- **Scheduling:** Processor sharing
- **Stato del sistema:**  
 $S(t) = (SI(t), n_{spike}(t))$ 
  - ▶  $SI(t)$ : Utenti nel Web server
  - ▶  $n_{spike}(t)$ : Utenti nello Spike server

# Parametri del modello

## Carico di lavoro

Processo iperesponenziale  
( $cv = 4$ )

- **Caso Base:**  $\lambda = 6.66$  req/s
- **Stress Test:**  
 $\lambda = \{1, 2, \dots, 12\}$  req/s

## Tempi di servizio

Distribuzione iperesponenziale  
( $cv = 4$ )

- **Web server:**  $E[S] = 0.16s$
- **Spike server (Base):**  
 $E[S] = 0.16s$
- **Spike server (Upgrade):**  
 $E[S] = 0.08s$

# Modello computazionale



# Roadmap

## 1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

## 2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale


## 3 Analisi Transitorio

## 4 Orizzonte temporale

## 5 Risultati


- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

# Analisi Transitorio




- 0-500s: Maggiore variabilità
- 500-1500s: Stabilizzazione
- Oltre 1500s: Fase transitoria conclusa

# Analisi Transitorio



**Figure 1:** Andamento del tempo di risposta medio per  $SI_{max} = 40$  e  $\lambda = 6.66$  con diversi seed



**Figure 2:** Andamento del tempo di risposta medio per  $SI_{max} = 120$  e  $\lambda = 6.66$  con diversi seed

# Roadmap

## 1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

## 2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale

## 3 Analisi Transitorio


## 4 Orizzonte temporale

## 5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

# Orizzonte temporale

- Tempo di simulazione totale: 5000s
  - ▶ Tempo adeguato per raggiungere la fase stazionaria in tutti i casi
  - ▶ Tempo di simulazione per fattibilità computazionale
- Fase di warm-up: 500s
  - ▶ Esclusa la parte iniziale per evitare l'influenza del transitorio
  - ▶ Alternativa possibile: 1500s



# Roadmap

## 1 Caso di Studio e Obiettivi

- Caso di Studio
- Obiettivi dello studio

## 2 Modello

- Modello concettuale
- Parametri del modello
- Modello computazionale

## 3 Analisi Transitorio


## 4 Orizzonte temporale

## 5 Risultati

- Obiettivo 1
- Obiettivo 2
- Obiettivo 3

# Obiettivo 1

Scenario con carico  $\lambda = 6.66$  req/s: analisi del tempo di risposta medio in funzione della soglia  $SI_{max}$ .



- Il tempo di risposta cresce all'aumentare di  $SI_{max}$
- $SI_{max} = 90$  è a rischio
- $SI_{max} = 80$ , massimizza l'uso del webserver mantenendo  $E[R] < 8s$

# Obiettivo 2

- Fino a  $\lambda = 7$  req/s

- ▶  $E[R] \nearrow$

- ▶  $SI < SI_{max}$

- da  $\lambda = 8$  req/s

- ▶ Spike server in azione


- ▶  $E[R] \searrow$

- da  $\lambda = 11$  req/s

- ▶ Saturazione spike server

- ▶  $E[R] \nearrow$


Scenario con vari scenari di soglia: analisi del tempo di risposta medio in funzione di  $\lambda = 1, 2, \dots, 12$  req/s.





# Obiettivo 3

Spike server potenziato del doppio  
( $E[S] = 0.08s$ ): analisi del tempo di risposta  
medio in funzione di  $\lambda = 1, 2, \dots, 12$  req/s.



- Comportamento equivalente all'obiettivo 2
- Spike server non si satura più

Grazie per l'attenzione!

# Domande?

Il codice è disponibile al seguente repository:

<https://github.com/LucaFalasca/CVRP-PLI-Euristich-Compare>